

Protótipo de um Assistente Conversacional Inteligente baseado em LLMs e RAG para o ensino de práticas esportivas de Artes Marciais

Renan Alves Tavares
Instituto de Ciência,
Tecnologia e Inovação
Universidade Federal de
Lavras
São Sebastião do
Paraíso, Minas Gerais,
Brasil
r.a.tavares2018@gmail.
com

Cauã Dias Tiago
Instituto de Ciência,
Tecnologia e Inovação
Universidade Federal
de Lavras
São Sebastião do
Paraíso, Minas Gerais,
Brasil
caua.tiago@estudante.
ufla.br

Diego Saqui
Instituto de Ciência,
Tecnologia e Inovação
Universidade Federal
de Lavras
São Sebastião do
Paraíso, Minas
Gerais, Brasil
diego.saqui@ufla.br

Rubens Antonio
Gurgel Vieira
Departamento de
Educação Física
Universidade Federal
de Lavras
Lavras, Minas Gerais,
Brasil
rubensgurgel@ufla.br

Álex Sousa Pereira
Departamento de
Educação Física
Universidade Federal
de Lavras
Lavras, Minas Gerais,
Brasil
alexpereira@ufla.br

ABSTRACT

This paper presents Dojufla Assistente IA, a prototype of an intelligent conversational assistant based on Retrieval-Augmented Generation (RAG), developed to support knowledge management in the Dojufla Martial Arts Program at the Federal University of Lavras (UFLA). The system integrates large language models with semantic information retrieval techniques, allowing users to perform natural language queries over a specialized document repository. Implemented using Python, Flask, FAISS, and Llama models, the prototype combines document processing, vector storage, and semantic retrieval. Preliminary results demonstrate the technical feasibility of the proposed architecture and the potential of generative artificial intelligence to support university extension activities and facilitate access to institutional knowledge.

In: Proceedings of the Brazilian Symposium on Multimedia and the Web (WebMedia'2026), Lavras/MG, Brasil. Porto Alegre: Brazilian Computer Society, 2026.

©2026 SBC – Sociedade Brasileira de Computação.

ISSN: 2966-2753

KEYWORDS

Retrieval-Augmented Generation; Large Language Models; Artificial Intelligence; Knowledge Management; University Extension.

1 Introdução

Grandes Modelos de Linguagem (*Large Language Models*, LLMs) nascem ao acoplar módulos de visão ou outros modos a LLMs já treinados, reaproveitando suas capacidades de raciocínio e linguagem [2, 3]. O avanço

recente dos LLMs tem impulsionado o desenvolvimento de sistemas capazes de compreender linguagem natural e auxiliar usuários em tarefas de busca, organização e produção de conhecimento, exibindo fortes habilidades de entendimento, geração e raciocínio em múltiplas tarefas, como garantia de qualidade, tradução, resumo e diálogo [8]. Esses avanços foram viabilizados principalmente pela arquitetura Transformer, que se tornou a base dos modelos de linguagem modernos devido à sua capacidade de processar sequências de forma eficiente e capturar dependências contextuais de longo alcance [10]. Entretanto, modelos de propósito geral podem apresentar limitações quando aplicados a domínios específicos. O treinamento em dados gerais leva a fraco desempenho em perguntas de domínios específicos (saúde, educação, direito e telecomunicações), exigindo customização ou apoio externo [1, 4].

Nesse contexto, técnicas de Geração Aumentada por Recuperação (*Retrieval-Augmented Generation*, RAG) têm se destacado por combinar a capacidade generativa dos LLMs com mecanismos de recuperação de informações, permitindo que respostas sejam fundamentadas em bases documentais específicas. O RAG diminui erros ao ancorar as respostas em documentos recuperados, sendo apontado como solução-chave para a adoção de chatbots em educação e outros domínios especializados [5, 6].

Diferentemente de sistemas que dependem exclusivamente do conhecimento previamente aprendido pelo modelo, a abordagem RAG consulta uma base documental especializada antes de gerar uma resposta, reduzindo alucinações e aumentando a precisão das informações fornecidas. Essa arquitetura combina indexação vetorial de documentos, recuperação semântica e geração de

respostas condicionada por LLMs, sendo amplamente adotada na literatura para sistemas de perguntas e respostas baseados em conhecimento especializado [9, 11]. Essa abordagem reduz problemas relacionados à geração de informações imprecisas e alucinações, além de possibilitar a construção de assistentes especializados capazes de apoiar processos organizacionais, educacionais e científicos [7].

No âmbito da extensão universitária, programas e projetos frequentemente enfrentam desafios relacionados à gestão do conhecimento, à organização documental e à disseminação de informações para estudantes, docentes e comunidade externa. A Escola de Artes Marciais da Universidade Federal de Lavras (Dojufla) constitui um ecossistema integrado de ensino, pesquisa e extensão que, ao longo dos anos, acumulou materiais pedagógicos, documentos institucionais e experiências relacionadas ao ensino das artes marciais, à promoção da saúde, à inclusão social e à formação cidadã.

Inserido no projeto “IA Popular para o Dojufla: Inteligência Artificial e Tecnologias Sociais voltadas à Formação e Gestão em Artes Marciais”, este trabalho busca contribuir para a ampliação e democratização do acesso ao conhecimento produzido pelo programa por meio de soluções tecnológicas acessíveis. A proposta está alinhada à perspectiva de utilização da inteligência artificial como ferramenta de apoio à gestão, à produção científica e à organização das atividades extensionistas, incentivando a transformação do conhecimento gerado pela extensão em resultados acadêmicos e sociais.

Dessa forma, este artigo apresenta um protótipo do Dojufla Assistente IA, um sistema de consulta inteligente baseado em RAG para apoio à gestão do conhecimento em artes marciais. A solução utiliza modelos de linguagem de grande escala integrados a uma base documental especializada, permitindo que usuários realizem consultas em linguagem natural sobre conteúdos relacionados às atividades do programa.

A arquitetura proposta combina técnicas de processamento de documentos, geração de *embeddings*, armazenamento vetorial e recuperação semântica de informações, utilizando ferramentas como FAISS e modelos da família Llama. O sistema foi concebido como um primeiro passo para a construção de uma plataforma mais ampla de apoio à gestão do Dojufla, que futuramente incluirá funcionalidades voltadas à automação de processos administrativos, acompanhamento de participantes, geração de relatórios e suporte à produção científica.

As principais contribuições deste trabalho são: (i) a proposição de uma arquitetura de assistente conversacional especializado para o domínio das artes marciais e da extensão universitária; (ii) a implementação de um protótipo baseado em RAG utilizando tecnologias

abertas; (iii) a demonstração da aplicação de LLMs como ferramenta de apoio à gestão do conhecimento e à democratização do acesso à informação; e (iv) a apresentação de resultados preliminares obtidos durante o desenvolvimento do sistema e perspectivas para sua evolução futura.

2. Metodologia

O desenvolvimento foi conduzido por meio de uma abordagem de prototipação incremental, visando à construção de um sistema de consulta inteligente capaz de recuperar e gerar respostas fundamentadas em documentos relacionados às atividades de artes marciais.

A solução foi implementada utilizando a linguagem Python como tecnologia principal de desenvolvimento, juntamente com o *framework* Flask para construção da aplicação web. A interface do sistema foi desenvolvida utilizando HTML e CSS, enquanto o armazenamento das informações dos usuários da aplicação foi realizado por meio do banco de dados SQLite. O ambiente de desenvolvimento foi configurado utilizando ambientes virtuais (venv), permitindo o isolamento das dependências e maior controle sobre as bibliotecas utilizadas no projeto.

A arquitetura do sistema foi baseada no paradigma RAG. No processo de construção da base de conhecimento, os documentos foram submetidos à etapa de *chunking*, na qual textos extensos são divididos em partes menores, facilitando o processamento e a recuperação de informações relevantes. Cada trecho textual foi convertido em representações vetoriais conhecidas como *embeddings*. Os *embeddings* transformam o conteúdo textual em sequências numéricas capazes de representar semanticamente o significado dos textos. Essas representações foram armazenadas em um banco vetorial (*vector store*) utilizando a biblioteca FAISS, responsável por realizar buscas de similaridade entre documentos de forma eficiente.

Durante o processo de consulta, a pergunta enviada pelo usuário também é transformada em *embedding* e comparada com os vetores armazenados no banco vetorial. Os documentos mais relevantes são recuperados e enviados juntamente com a consulta para o modelo de linguagem, formando o contexto utilizado na geração da resposta.

Foram utilizados modelos da família Llama. Localmente, o sistema emprega o modelo Llama 3 com 8 bilhões de parâmetros, executado localmente por meio do Ollama. Além disso, foi disponibilizada uma alternativa em nuvem utilizando a infraestrutura Groq, que fornece acesso ao modelo Llama 3.3 com 70 bilhões de parâmetros via API, permitindo respostas mais elaboradas e maior capacidade de raciocínio quando necessário.

Os modelos utilizados são baseados na arquitetura Transformer, que emprega mecanismos de atenção para analisar simultaneamente todas as palavras de uma sequência textual, permitindo compreender relações contextuais complexas entre diferentes partes do texto. Durante a geração das respostas, o sistema utiliza streaming, possibilitando que o conteúdo seja exibido progressivamente ao usuário à medida que é produzido pelo modelo.

3. Resultados Preliminares

Ainda em fase de testes e processo contínuo de aprimoramento, o protótipo foi implementado com sucesso, integrando mecanismos de recuperação semântica de

informações e geração de respostas por meio de LLMs, conforme ilustrado nas figuras das principais interfaces desenvolvidas. Atualmente, a aplicação é composta por seis telas principais: Login, Cadastro, Quem Somos, Re-Treino da IA, Consulta Administrador e Consulta Usuário Comum. Essas interfaces foram projetadas para proporcionar uma experiência intuitiva aos usuários, além de disponibilizar funcionalidades voltadas à consulta de informações, gerenciamento da plataforma e atualização da base de conhecimento.




Figura 1: Tela de Consulta da IA

Fonte: Elaborado pelos autores (2026)

A tela de consulta constitui a principal interface da aplicação e foi a primeira funcionalidade desenvolvida no sistema. Nela, tanto usuários administradores quanto usuários comuns possuem acesso ao assistente virtual, podendo realizar perguntas em linguagem natural sobre os conteúdos presentes na base de conhecimento. As respostas são exibidas de forma progressiva por meio de *streaming*, proporcionando uma experiência de interação mais dinâmica e semelhante à observada em assistentes conversacionais modernos.

Além disso, a interface disponibiliza duas opções para processamento das consultas: uma execução local, utilizando o modelo Llama por meio da plataforma Ollama, e uma execução em nuvem, realizada através da API da

Groq. A tela também oferece a funcionalidade de limpeza do histórico da conversa, permitindo ao usuário reiniciar a interação sempre que necessário.

A Figura 02 apresenta a tela exclusiva destinada aos administradores da plataforma. Por meio dessa interface, é possível realizar o envio contínuo de novos documentos em formato PDF para a base de conhecimento do sistema. Após a inserção de novos arquivos, o administrador pode executar novamente o processo de treinamento da base vetorial, permitindo que as informações recém-adicionadas sejam processadas, indexadas e incorporadas ao pipeline RAG. Dessa forma, o assistente mantém sua base de conhecimento constantemente atualizada, ampliando sua

capacidade de fornecer respostas contextualizadas e alinhadas aos documentos mais recentes.



Figura 2: Tela de Re-Treino da IA

Fonte: Elaborado pelos autores (2026)

Além disso, a aplicação está integrada a um banco de dados responsável pelo gerenciamento e autenticação dos usuários. Ao acessar o sistema, o usuário pode criar uma conta ou realizar login com credenciais previamente cadastradas, possibilitando o controle de acesso aos diferentes perfis da plataforma. O sistema também disponibiliza uma página institucional contendo informações gerais sobre o projeto e seus objetivos.

Os resultados obtidos até o momento demonstram a viabilidade técnica da integração entre recuperação semântica de informações e modelos de linguagem para apoio às atividades do Dojufla, permitindo consultas contextualizadas sobre documentos institucionais e fornecendo uma base para futuras avaliações de desempenho e usabilidade.

4. Conclusão

Este trabalho apresentou o desenvolvimento de um protótipo de um assistente IA, uma solução baseada na arquitetura RAG voltada ao apoio das atividades de formação, gestão e disseminação do conhecimento em artes marciais. A integração entre recuperação semântica de documentos e LLMs possibilitou a construção de um sistema capaz de fornecer respostas contextualizadas a partir de uma base documental especializada, contribuindo para a democratização do acesso à informação no âmbito do projeto.

Os resultados obtidos demonstram a viabilidade da utilização de técnicas de inteligência artificial generativa associadas à recuperação de informações para apoiar projetos de extensão universitária. Além disso, a implementação de mecanismos para atualização contínua da base de conhecimento permite que novos documentos sejam incorporados ao sistema de forma simples e eficiente.

Como trabalhos futuros, pretende-se aprimorar a estrutura do banco de dados, visando aumentar a segurança, a escalabilidade e o gerenciamento dos usuários administradores da plataforma. Também está prevista a evolução da integração com o *framework* LangChain, possibilitando a expansão do pipeline RAG e a melhoria dos processos de recuperação e geração de respostas.

Além disso, pretende-se incorporar novas funcionalidades, como histórico de conversas e uma interface de interação em formato de chat, proporcionando uma experiência semelhante à observada em assistentes conversacionais modernos. Por fim, espera-se realizar a implantação institucional da solução em infraestrutura da Universidade Federal de Lavras (UFLA), ampliando sua disponibilidade e permitindo o acesso por um número maior de usuários vinculados ao projeto e à comunidade acadêmica.

AGRADECIMENTOS

Os autores agradecem à Universidade Federal de Lavras (UFLA) pelo apoio institucional ao desenvolvimento deste

trabalho. Este projeto foi realizado com apoio do Programa de Inovação para Projetos em Ciência, Tecnologia e Ação Empreendedora (Inov@ção UFLA), conforme o Edital PRPI nº 06/2025, promovido pela Pró-Reitoria de Pesquisa e Inovação (PRPI). Os autores também agradecem ao Programa de Artes Marciais da UFLA (Dojufila) pelo suporte durante o desenvolvimento da pesquisa.

REFERÊNCIAS

- [1] J. Agada, A. Folashade, T. Ghosal, and A. Biswas. 2025. A systematic review of key retrieval-augmented generation (RAG) systems: progress, gaps, and future directions. arXiv. DOI: <https://doi.org/10.48550/arXiv.2507.18910>.
- [2] D. Caffagni et al. 2024. The revolution of multimodal large language models: a survey. In Proceedings of the Findings of the Association for Computational Linguistics: ACL 2024, Bangkok, Thailand, pp. 13590–13618. DOI: <https://doi.org/10.18653/v1/2024.findings-acl.807>.
- [3] D. Huang, C. Yan, Q. Li, and X. Peng. 2024. From large language models to large multimodal models: a literature review. Applied Sciences, 14(12), 5068. DOI: <https://doi.org/10.3390/app14125068>.
- [4] E. Sanu, T. K. Amudaa, P. Bhat, G. Dinesh, A. U. K. Chate, and R. K. P. 2024. Limitations of large language models. In Proceedings of the 8th International Conference on Computational System and Information Technology for Sustainable Solutions (CSITSS), Bengaluru, India, pp. 1–6. DOI: <https://doi.org/10.1109/CSITSS64042.2024.10817070>.
- [5] S. Siriwardhana, R. Weerasekera, E. Wen, T. Kaluarachchi, R. Rana, and S. Nanayakkara. 2023. Improving domain adaptation of retrieval augmented generation (RAG) models for open domain question answering. Transactions of the Association for Computational Linguistics, 11, 1–17. DOI: https://doi.org/10.1162/tacl_a_00530.
- [6] J. Swacha and M. Gracel. 2025. Retrieval-augmented generation (RAG) chatbots for education: a survey of applications. Applied Sciences, 15(8), 4234. DOI: <https://doi.org/10.3390/app15084234>.
- [7] S. Wang et al. 2024. DomainRAG: a Chinese benchmark for evaluating domain-specific retrieval-augmented generation. arXiv. Available at: <https://arxiv.org/abs/2406.05654>.
- [8] W. X. Zhao et al. 2023. A survey of large language models. arXiv. DOI: <https://doi.org/10.48550/arXiv.2303.18223>.
- [9] Y. Gao, Y. Yun, X. Gao, B. Pan, and L. Wang. 2024. Retrieval-Augmented Generation for Large Language Models: A Survey. arXiv. DOI: <https://doi.org/10.48550/arXiv.2312.10997>.
- [10] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, and I. Polosukhin. 2017. Attention Is All You Need. arXiv. DOI: <https://doi.org/10.48550/arXiv.1706.03762>.
- [11] P. Zhao, H. Zhang, Q. Yu, Z. Wang, Y. Geng, F. Fu, L. Yang, W. Zhang, J. Jiang, and B. Cui. 2024. Retrieval-Augmented Generation for AI-Generated Content: A Survey. arXiv. DOI: <https://doi.org/10.48550/arXiv.2402.19473>.